

大数据总复习

Wednesday, December 17, 2025 8:15 AM

前面看笔记，后面继续

Chap1：大数据 云计算三者之间的关系，肯定也得考察，简答形式

Chap2：处理流程：流程6部曲。业务理解可有可无。每一步都有哪些技术要清楚

传统文件系统，数据存储有哪些

分布式文件系统要考察，图形结构的基本框架要清楚。newsqI, nosql要知道干什么用的

数据分析部分，常见方式，

数据的呈现，可视化。大数据可视化流程一张图应该理解。

Chap3：大数据技术

1.数据采集预处理，

采集方法有哪些，可能的采集方法得列出，实时离线互联网。预处理部分，清洗集成变换规约。每个内容都在做什么。搞清楚概念举例子，给个表格数据要找出问题和清洗。表格数据存在什么样的类型？数值等级名义布尔

数据基本统计信息能不能发现问题

数据质量评估，准确一致完整时效，但没有量化方法可背。

异常值处理——检测，删除，异常值分析

数据集成是做什么

数据变换很重要，要进行规范化处理。——简单函数变换，规范化最小，连续属性离散化，属性构造。

数据归约是神马，了解一下就ok

2.数据存储和管理

分布式文件系统，如何评价一个分布式文件系统，分布策略，冗余备份是重点。

hdfs目标是什么，适合做什么事情。结构和图示要掌握。HDFS读写过程可以简略。

分布式数据库，

首先了解一下和关系数据库的不同，传统数库不能满足海量数据，高效开发和？。

Hbase是核心模块，要了解，干嘛的有什么特点。

Hbase数据模型基本概念，表行列族时间戳键等等。

Hbase实现原理。映射表格实际上是，表值是字符串，同一个列族存储到一起。更新不删旧版本。

Hbase vs 关系数据库，区别是重点！！比如hbase没有复杂表间关系。

非关系数据库，nosql是什么，是hbase的例子，有什么特点，能干什么，为什么使用它？

语义数据库，语义查询有什么进步，语义网络智能推理

云数据库简单了解ok

3.数据处理和分析，非常多！！

mapredoce模型，必考！！首先他和hadoop之间的关系，是属于hadoop的核心架构一部分。

他是分布式运算编程框架，下面的图了解一下ok

mapreduce编程模型要清楚。优先缺点要记住，再不行看看通俗解释。考试的时候任务可能变一变，比如聚类出行，可能有一堆数据存储在不同机器上，那么不同服务器进行什么操作，共同好友实例比较难，这个要看一看就ok。不会那么杂

相关性分析，是做什么的，要先了解清楚。常见相关性系数。

数据基本描述角度，中心趋势，离散程度，分布度量，图形化分析。下头公式不用掌握，但是红色的要知道咋算。例子有意思，可以看一看。标准差方差都需要掌握，

可视化分布了解一下就ok

思考部分很重要，出实际问题让人思考！角度要全。

算法包括，连接分析 关联分析 分类算法 聚类算法

链接：pagerank要求看懂

关联：apriori

剩下的没讲细节，知道能干嘛就行，有什么性质。

****pagerank** 用来做什么，排序网页。基本思想就是简化互联网。pagerank公式必须记住会算！！！！**

pagerank一般定义也要掌握，迭代公式要知道。迭代公式忘记加后面部分的人很多！中间的写对了很重要。错的根本原因是不理解。

大数据模型重点解决的是节点任务？重要的是图神经网络。图卷积过程和公式其实不重要，但重点是聚合了什么，学习了什么，关联关系是干什么的。

端到端学习，流程图很重要。本身怎么建，能利用什么，怎么考虑建关联关系，图神经网络起什么作用，要求有分析过程。

剩余花花绿绿的图了解就ok

可视化一整张都不是重点，但要清楚为什么要可视化，可视化不只是结果可视化。

Chap4 大数据工具，

数据清洗工具，

hadoop核心组件，有哪些，包含什么关键技术，

除了核心的，想mahout这类是干啥的，了解即可

数据可视化不是重点。

spark也要掌握，hadoop存在的缺点，spark解决。二者的区别重点掌握。

去年考了对比！！分别适合什么场景，spark的生态。

Chap5 大数据应用，会考！！

要搞清楚数据是什么，任务是什么，模型输入输出是什么，案例来自ppt，模型不重要，任务理解清楚。

Chap6 大数据伦理安全

案例要清楚是什么事情，案例不会考，会考即使，关于密码学的了解一下，加密解密。

深度学习下的数据安全，重点！理解可能的攻击，考虑一下如何刘后门。不会多难，但肯定要

靠。

6-7道大题，数据处理流程5.

往后都是综合，