

北京工业大学 2025——2026 学年第 1 学期

《模式识别 II》 考试试卷 A 卷

考试说明： 考试时间：95 分钟； 考试形式：闭卷

适用专业：人工智能

承诺：

本人已学习了《北京工业大学考场规则》和《北京工业大学学生违纪处分条例》，承诺在考试过程中自觉遵守有关规定，服从监考教师管理，诚信考试，做到不违纪、不作弊、不替考。若有违反，愿接受相应的处分。

承诺人： 学号： 班号：

注：本试卷共 五 大题，共 6 页，满分 100 分，考试时必须使用卷后附加的统一答题纸或草稿纸。请将答案统一写在答题纸上，答案写在其他位置造成的成绩缺失由考生自己负责。

卷面成绩汇总表（阅卷教师填写）

题号	一	二	三	四	五	总成绩
满分	20	20	10	20	30	
得分						

得分

一、解释和判断题（每题 2 分，共 20 分）

请在答题纸对应题号下方空格处为正确说法打√，错误说法打×。

1. 事件 A 发生的概率可以看作为随机变量。因此，事件 A 发生的概率可以假设被一系列的因子 $\{x_1, \dots, x_N\}$ 所控制。我们假设每个因子都相互独立，我们可以设计不同的概率 $\{p(x_1|\theta_1), \dots, p(x_N|\theta_N)\}$ 来控制，其中， θ_i 表示概率密度的参数。
(对)

解释：

2. 在贝叶斯公式 $P(\theta|D) = P(D|\theta)P(\theta)/P(D)$ 中，“消元”是指对先验概率 $P(\theta)$ 所有可能取值求和（离散型）或积分（连续型）以得到证据 $P(D)$ 。（错）

解释：消元的核心是“边缘化参数 θ ”是 $P(D) = \sum_{\theta} P(D|\theta)P(\theta)$ 而不是对 $P(\theta)$

进行求积分。

3. 基于贝叶斯公式的迭代更新中，如果已经有证据 D1。当观测到新的证据 D2 时，需以初始先验 $P(\theta)$ 结合似然 $P(D1 | \theta)P(D2 | \theta)$ ，后验为

$$P(\theta|D1, D2) = \frac{P(\theta|D1)P(\theta|D2)}{P(D2|D1)}。 \quad (\text{错})$$

解释：贝叶斯公式的迭代更新中，旧的后验 $P(\theta|D1)$ 变为先验，而非沿用初始先验 $P(\theta)$ ，此时新后验为： $P(\theta|D1, D2) = \frac{P(D2|\theta)P(\theta|D1)}{P(D2|D1)}$

4. 在一个模式识别系统中，数据的多维度采集方式（如，红外，可见光，远红外）一定能有助于提高模型的性能。（错）

解释：对模型性能的提升并非“必然”，其效果依赖于数据质量、模态互补性、融合方法、应用场景等多重条件，存在“增益”“无效”甚至“负增益”三种可能，因此“一定能提高性能”的表述不符合模式识别的实际规律。

5. 我们可以只用证据进行推断，也可加上对参数的先验知识以正则化的形式对模型参数增加约束。因此，加上正则化一定会提高模型的性能。（错）

解释：正则化属于先验，正则化的有效性依赖于“先验知识与真实数据分布一致”；此外，正则化强度需适配模型复杂度。正则化对模型性能的提升是“条件性增益”，而非“必然性结果”，题干中“一定会”的绝对化表述错误。

6. 在感知机中，替代函数可以设计成指数损失函数。我们对替代函数的设计原则是原函数的紧上界（对于求最小化问题而言）。（对）

解释：

7. Logistic 的损失函数和 KL 距离（KL divergence）优化目标是一致的。（对）

解释：

8. 在有限样本条件下，受“维度灾难”影响，高维样本的概率密度难以进行准确估计。（对）

解释：

9. 可以利用泰勒展开理解 Boosting，Boosting 为函数空间的一阶梯度下降。（对）

解释：

10. 直方图在概率估计中无法扩展到高维空间中进行概率密度估计（对）

得分

二、单选题（共 20 分，每题完全选对得 2 分）

请在答题纸对应题号下方空格处填入 A、B、C、D 中的一个选项。

1. 关于机器学习中，以下哪种学习方式是让模型自己发现数据中的模式，没有给定明确的输出标签？（ B ）
A. 监督学习 C. 强化学习
B. 无监督学习 D. 半监督学习
2. 模式识别中，用于把高维数据映射到低维空间的技术是（ C ）
A. 特征提取
B. 特征选择
C. 降维技术
D. 分类技术
3. 在模式识别中，关于 “将高维数据映射到低维空间” 的技术，下列说法错误的是（ B ）。
A. L1 特征选择通过选择特征形成低维特征以保留数据核心信息
B. PCA 是特征提取方法，其核心是通过映射或筛选获得低维表示，且特征提取会生成新特征而非保留原有特征
C. 特征提取与降维技术是完全独立的概念
D. 非线性技术（如核方法）不属于 “高维数据到低维空间的映射技术” 范畴
4. 在根据问题建立模型阶段，以下哪种因素最重要？（ C ）
A. 模型的复杂度
B. 模型的可解释性
C. 模型是否适合问题类型
D. 模型的训练速度
5. 在模式识别的 “问题建模阶段”（即根据具体任务需求设计 / 选择模型的初始阶段），下列关于核心影响因素的说法，最准确的是（ ）。

- A. 高风险场景（如医疗诊断）中，模型的可解释性优先于问题适配性，因为可解释性直接决定结果是否可信，无需严格匹配问题类型
- B. 模型需首先满足“与问题的任务类型、数据分布、核心目标完全适配”，在此前提下，再根据场景需求权衡复杂度、可解释性等次要因素
- C. 模型复杂度是核心指标，复杂模型（如深度学习）能覆盖更多问题类型，因此无需刻意匹配问题类型，我们用复杂的模型即可
- D. 问题建模阶段的核心是快速验证可行性，因此模型的训练速度比问题适配性更重要，训练速度快的模型可快速迭代优化

6. 独立同分布假设意味着样本之间（C）

- A. 完全没有关系
- B. 只有顺序关系
- C. 有相同的分布且相互独立
- D. 分布相同但相互依赖

7. 在机器学习与统计推断中，样本的“独立同分布（i.i.d.）假设”是许多模型（如极大似然估计、朴素贝叶斯）的核心前提。关于该假设，下列说法最严谨的是（B）

- A. 连续 7 天采集同一城市的日最高气温，分析该城市气温的统计规律
- B. 从某电商平台的所有用户中，随机抽取 1000 名用户的单次消费金额，用于训练用户消费能力预测模型
- C. 要求样本之间相互独立且服从相同的边缘分布，但允许样本存在弱相关性（如线性相关系数 $\neq 0$ ）
- D. 记录某医院同一患者连续 10 次复诊的血压值，用于构建该患者的血压变化预测模型

8. 在最大似然估计中，如果没有独立同分布假设，联合概率密度（B）

- A. 仍然可以简单地写成连乘形式
- B. 可能需要用更复杂的形式表示

- C. 无法计算
D. 等于各个概率密度之和

9. 在最大似然估计 (MLE) 中, 独立同分布 (i.i.d.) 假设是简化联合概率密度计算的前提。若去除该假设, 关于样本的联合概率密度, 下列说法最严谨的是 (B)

- A. 仍可简单表示为各样本边缘概率密度的连乘形式, 因连乘是联合密度的固有表达, 与独立性无关
B. 可能需要用更复杂的形式 (如条件概率乘积、结构化依赖模型) 表示, 具体取决于样本间的依赖关系与分布特性
C. 完全无法计算, 因 MLE 的核心逻辑依赖 i.i.d. 假设, 无此假设则联合密度的表达式不存在
D. 等于各个样本边缘概率密度之和, 因非独立场景下需通过求和体现样本间的关联

10. 以下哪种情况最符合独立同分布假设 (C)

- A. 股票价格在不同日期的变化
B. 学生考试成绩在不同科目间的分布
C. 多次抛硬币的结果
D. 一个人不同年龄段的身高变化

得分

三、填空题 (每题 2 分, 共 10 分)

请在答题纸对应题号后的空格处顺序填写答案。

1. 在最大后验估计 (MAP) 中, 如果先验分布是均匀的, 则 MAP 估计等价于 最大似然 MLE。
2. 感知机解的对偶形式将 梯度下降的向量空间 转换为样本之间的 内乘积空间。
3. 感知机解的对偶形式中, 若初始权重 $w_0 = 0$, 可将权重向量 w 表示为 训练样本与对应标签 的线性组合, 进而将原始形式中 “ $w x^T$ ” 的核心运算转换为 待测样本与所有样本的内积, 该转换的计算效率优化依赖于预先计

算的 Gram (矩阵名称)，其元素定义为训练样本间的内积。

4. adaBoost 算法如果需要训练 M 个弱分类器，而每个弱分类器的时间复杂度为 $O(h)$ ，那么 adaboost 的时间复杂度为 $O(Mh)$ 。

得分

四、计算题（每题 5 分，共 20 分）

请在答题纸对应题号后的空格处顺序填写答案。

1. 令 $D = \{x_1, x_2, \dots, x_n\}$ 为从指数分布中独立同分布采样得到的样本，其概率密度函数为：

$$P(x) = \begin{cases} \lambda \exp(-\lambda x) & \text{if } x \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

其中， $\lambda > 0$ 是参数，找出 λ 的最大似然估计（5 分）。

2. 已知混淆矩阵 $TP = 70, FP = 30, FN = 10, TN = 90$ （5 分）。

(1) 计算假正例率 (FPR)（2 分）。

(2) 计算召回率（3 分。）

解：FPR=0.25。

3. 多分类 Logistic 回归 (Softmax 回归) 处理 3 分类任务（类别 0、1、2），某训练批次包含 3 个样本。已知：

样本 1: Softmax 预测概率 $p_1 = [0.1, 0.3, 0.6]$,

真实标签为类别 1 (one-hot 编码 $y_1 = [0, 1, 0]$)；（5 分）。

(1) 给出样本 1 的交叉熵损失表达式。（2 分）

(2) 以样本 1 为例，推导并计算交叉熵损失对其 Softmax 前的线性输出 (logits z_0, z_1, z_2 中， z_0 的梯度。（3 分）

4. 算输入值为 -1 时 Sigmoid 函数的输出值（2 分），并解释含义（3 分）。

答案：约为 0.27，表示正类的概率为 27%

5. Sigmoid 函数是二分类 Logistic 回归的核心激活函数，请结合函数性质与实际应用完成以下分析，以阈值 0.5 为分类标准：

- (1) 输入 $x = -1$ 时，模型预测类别是什么？（2 分）
- (2) 若将阈值调整为 0.3，预测类别是否改变？说明理由。（3 分）

得分

五、分析题（每题 5-10 分，共 30 分）

请在答题纸对应题号下方标明具体题号、顺序作答。

1. 在线性分类器 $y = \mathbf{w}^T \mathbf{x} + b$ 为基础的感知机或 logistic 回归中，我们通常需要对输入向量 $\mathbf{x}$ 进行归一化。请分析模式识别系统里面：
 - (a) 归一化有哪些方法，请列出 2 种，并解释每种归一化方法的特点；（2 分）：
 - (b) 综合 $y = \mathbf{w}^T \mathbf{x} + b$ 数学表达式和对推理证据信 $\mathbf{x}$ 任度的角度，详细阐述为什么一定需要对输入进行归一化的原因（3 分）；
2. 分析 Sigmoid 函数在不同输入区间的敏感性？（5 分）
 答案：输入接近 0 时最敏感，远离 0 时不敏感

3. 分析 Sigmoid 函数：

- (1) 在不同输入区间的敏感性的特点？（2 分）
- (2) 不同敏感区带来的好处和问题？（3 分）

答案：（1）分成 2 段，敏感区；会导致输出概率从显著波动至；不敏感区，与之相反。

（2）敏感区的好处：梯度变化快，在决策边界 0.5 处，分类敏感性强；

不敏感区的好处：梯度变化慢，对异常样本（样本值过大）不敏感（其梯度为 0）；

不敏感区的坏处：梯度过小，神经网络梯度消失。