

北京工业大学 2024——2025 学年第 1 学期

《模式识别 II》 考试试卷 B 卷

考试说明： 考试时间：95 分钟； 考试形式：闭卷

适用专业：人工智能

承诺：

本人已学习了《北京工业大学考场规则》和《北京工业大学学生违纪处分条例》，承诺在考试过程中自觉遵守有关规定，服从监考教师管理，诚信考试，做到不违纪、不作弊、不替考。若有违反，愿接受相应的处分。

承诺人： 学号： 班号：

注：本试卷共 五 大题，共 6 页，满分 100 分，考试时必须使用卷后附加的统一答题纸或草稿纸。请将答案统一写在答题纸上，答案写在其他位置造成的成绩缺失由考生自己负责。

卷面成绩汇总表（阅卷教师填写）

题号	一	二	三	四	五	总成绩
满分	20	20	10	20	30	
得分						

得分

一、判断题及解释题（每题 4 分，共 40 分）

请在答题纸对应题号下方空格处为正确说法打√，错误说法打×，并对错误说法进行解释。

1. 随着事件 A 发生的频次越高，对事件 A 发生的概率估计就越准确。（错）
解释：结论不完全正确，其成立依赖严格的前提条件，核心误区在于混淆了“事件 A 发生的频次”与“试验的独立重复次数”，且忽略了概率估计准确性的本质影响因素。

2. 模式识别中，对于一个分类器模型而言，要求特征的大小归一化到 0-1 之间。

（错）

解释：朴素贝叶斯的核心是计算“特征条件概率 $P(x|y)$ ”，其概率估计依赖特

征的分布形态（如高斯朴素贝叶斯假设特征服从正态分布），归一化会改变特征的分布参数（如均值、方差），可能导致概率估计偏差，因此通常无需归一化。

标准化 (Z-score) 通过对特征减去_____，然后除以_____，使特征具有零均值和单位方差。

答案：均值；标准差

3. 对模式识别系统而言，Z-score 归一化可以将特征归一化到 0-1 之间。（错）

解释：这个结论错误，核心误区是混淆了「Z-score 标准化」与「Min-Max 归一化」的本质差异——Z-score 的核心是将特征转化为「均值为 0、方差为 1」的标准化分布，而非将数值限定在 0-1 区间，其数值范围完全由原始数据的分布特性决定，不局限于 0-1。

4. 在线性分类器 $y = \mathbf{w}^T \mathbf{x} + b$ 中，偏置 b 的大小会随着 $\mathbf{x}$ 维度的增加而增加。（错）

解释：标量参数（与维度 d 无关），物理意义是决策边界中的平移量，数学上对应“当 $\mathbf{w}^T \mathbf{x} = 0$ 时，分类结果由 b 决定”（如 $b > 0$ 则判定为正类， $b < 0$ 则为负类）。 $\mathbf{w}^T \mathbf{x}$ 已经表示维度变量已经消失。

5. 因为 sigmoid 函数是非线性函数，所以用 $y = \mathbf{w}^T \mathbf{x} + b$ 作为分类器的 Logistic 回归具有非线性分类能力。（错）

解释：Logistic 回归是线性概率模型，其核心结构由“线性变换 + 非线性激活”两部分组成，但非线性激活不改变模型的线性本质。

6. Boosting 算法的弱分类器之间是串行依赖。（对）

解释：。

7. Boosting 算法的非线性能力是从单个弱分类的非线性能力中获得。（错）

解释：Boosting 的非线性能力本质来自弱分类器的互补组合，而非单个弱分类器的非线性。

特征归一化的核心目标是将不同量纲的特征转化到_____上，以避免特征对模型训练的影响。

答案：同一尺度；不均衡

8. 特征归一化的目标是将不同量纲的特征转化到同一尺度（消除尺度差异），其主要作用是避免大尺度特征主导模型决策、导致训练偏差的不均衡影响，

而 Z-score 标准化虽未将数据限定在固定区间,但仍满足该核心目标。(对)
解释:

有放回采样的本质是每次抽样是_____的。

答案: 同分布

9. 有放回采样的本质是每次抽样相互独立且服从同一分布,可直接用于
Bootstrap、随机森林等依赖独立样本的机器学习算法。(错)

解释: 不满足独立性, 样本之间有相关性

Bagging 集成偏差减少的核心假设是弱学习器在同一数据上的偏差趋于_____。

答案: 一致

解析: 偏差一致性是降低集成偏差的重要因素。

10. Bagging 集成方法能减少模型偏差的核心假设是: 所有弱学习器在同一训练
数据上的偏差趋于一致, 通过平均组合可抵消随机误差, 从而降低整体模型
的偏差。()

解释: bagging 减少的是方差

得分

二、单选或多选题 (共 20 分, 每题完全选对得 2 分)

请在答题纸对应题号下方空格处填入 A、B、C、D、E 中的一个选项,
多选或错选都不记分。

1. 关于感知机中线性函数 $y = \mathbf{w}^T \mathbf{x} + b$ 的 b 与逻辑斯回归(Logistic)中 $y = \mathbf{w}^T \mathbf{x} + b$ 中的 b , 哪些说法是错误的 (E)。

- A. 感知机中的 b 与逻辑斯回归中的 b 作用不相同
- B. 感知机中的 b 比逻辑回归中的 b 难求解
- C. 逻辑斯回归中的 b 是为了让概率和为 1
- D. 在梯度下降过程中, 逻辑斯回归中的 b 和 $\mathbf{w}$ 可以用不同的学习率

2. 在 Bagging 集成中, 哪些模型更适合作为弱学习器以减少偏差? ()。

- A. 偏差较小的模型
- B. 偏差较大的模型
- C. 方差较大的模型
- D. 方差较小的模型

答案: A

3.在 Bagging 集成框架中,若目标是通过集成进一步减少强学习器的方差,下列关于弱学习器的选择,最合理且符合理论逻辑的是 (C)

A. 偏差较小但方差中等的模型(如深度适中的决策树),因其自身已具备一定拟合能力,集成后可通过独立样本训练抵消部分残余偏差

B. 偏差较大但方差极小的模型(如决策树桩、线性感知机),因其方差稳定, Bagging 可通过多模型组合逐步修正系统性偏差

C. 方差较大但偏差极小的模型(如深度极深的决策树),因其拟合能力极强,集成后能同时降低方差与偏差

D. 线性模型(如线性回归、逻辑回归),因其偏差与方差均较低,是 Bagging 集成中适配性最强的弱学习器

4. Bagging 的偏差不变是因为 ()。

A. 偏差与模型的平均预测值无关

B. 偏差由数据本身决定

C. 多个学习器的预测结果具有独立性

D. 偏差只与噪声有关

答案: C

解析: Bagging 的偏差不变源于独立学习器的平均值等于单个学习器的期望值。

5. Bagging 集成框架中,模型整体偏差近似不变(仅轻微波动,远低于方差降低幅度)的核心原因是 (C)

A. 偏差是模型预测与真实值的系统性差距,与多个学习器的平均预测值无关,仅由单个学习器的拟合能力决定

B. 偏差由数据的固有分布与噪声水平共同决定,集成策略无法改变数据本身的特性,因此偏差保持不变

C. 弱学习器通过 Bootstrap 采样实现独立同分布训练,集成预测的期望等于单个弱学习器的期望,导致偏差与单个学习器偏差近似相等

D. 偏差仅由数据噪声决定(不可约误差), Bagging 的组合策略无法降低噪声,因此偏差不变

C. 训练数据不均衡导致交叉熵损失函数失去凸性，梯度下降陷入局部最优，模型同时出现多数类过拟合与少数类欠拟合

D. 模型对 “交通事故” 样本的概率估计系统性偏高，但默认决策阈值 (0.5) 过高，导致大量真实事故样本因预测概率低于阈值被误判

9.(选项场景)逻辑斯回归在数据不均衡场景中 (如少数类占比 $< 10\%$) 的核心问题是分类边界偏向多数类，导致少数类召回率极低。下列哪个场景中，问题本质、解决方案与效果的匹配度最高，最能印证这一核心逻辑? (B)

A 医疗影像诊断中，用逻辑斯回归识别 “恶性肿瘤” (少数类，占比 3%) 与 “良性结节” (多数类，占比 97%)，模型测试集多数类准确率 96%，少数类召回率仅 8%。解决方案：对少数类样本进行特征工程 (如增加纹理、边缘特征)，未调整损失函数或样本分布。效果：少数类召回率提升至 10%，无显著改善。

B.智能交通事件检测中，用逻辑斯回归识别 “交通事故” (少数类，占比 5%) 与 “正常通行” (多数类，占比 95%)，模型测试集多数类准确率 98%，少数类召回率 15%。解决方案：采用 “类别权重平衡” (给少数类样本赋予 19 倍损失权重) 过采样，修正梯度更新偏向性。效果：少数类召回率提升至 78%，多数类准确率维持 92%。

C. 金融欺诈检测中，用逻辑斯回归识别 “欺诈交易” (少数类，占比 2%) 与 “正常交易” (多数类，占比 98%)，模型训练时梯度波动大，测试集多数类与少数类准确率均低于 70%。解决方案：调整学习率 (从 0.01 降至 0.001) + 增加迭代次数，确保模型收敛至全局最优。效果：多数类准确率提升至 95%，少数类召回率仍仅 12%。

D. 电商虚假评论识别中，用逻辑斯回归识别 “虚假评论” (少数类，占比 8%) 与 “真实评论” (多数类，占比 92%)，模型测试集少数类预测概率普遍偏高 (如真实虚假评论预测概率多在 0.6-0.7)，但仍有大量样本因阈值 0.5 被误判为真实评论。解决方案：将决策阈值从 0.5 降至 0.3，降低少数类分类门槛。效果：少数类召回率提升至 65%，但多数类准确率骤降至 75%

10 (与别的知识点结合) 逻辑斯回归在数据不均衡场景 (少数类占比 $< 10\%$) 中，核心矛盾是多数类损失主导梯度更新，导致分类边界偏向多数类。下列场景

中，最合理的方案是（ A ）

A. 金融欺诈检测（欺诈交易占比 3%），逻辑斯回归模型测试集多数类准确率 97%，少数类召回率 10%。解决方案：改进交叉熵损失，通过降低易分多数类样本的损失权重，强化少数类（难分样本）的损失贡献。

B. 工业质检（不合格产品占比 6%），逻辑斯回归模型测试集少数类召回率 9%，且预测概率校准度差（少数类概率被系统性低估）。解决方案：将决策阈值从 0.5 降至 0.2。效果：少数类召回率提升至 68%，多数类准确率降至 70%，因概率校准修正了梯度偏置，阈值调整进一步优化了分类结果。

C. 智能交通事件检测（交通事故占比 4%），逻辑斯回归模型测试集少数类召回率 8%，且训练集与测试集性能差距小（无过拟合）。解决方案：同时引入 L1 正则化（抑制特征冗余）与采样技术补充少数类样本。

D. 电商虚假评论识别（虚假评论占比 7%），逻辑斯回归模型因少数类样本特征稀疏，导致分类边界偏向真实评论。解决方案：对所有样本进行 Z-score 标准化（消除量纲差异），并增加迭代次数确保模型收敛至全局最优。

得分

三、填空题（每空 2 分，共 10 分）

请在答题纸对应题号后的空格处顺序填写答案。

1. Sigmoid 函数导数的最大值为 0.25。

2. 在逻辑斯回归中，增加少数类的 权重 可以缓解数据不均衡问题。

答案：权重

解析：为少数类增加权重，可以提高模型对少数类样本的关注度。

3. 在逻辑斯回归处理数据不均衡（少数类占比 $< 10\%$ ）问题时，通过为少数类样本赋予更高的 损失权重，可在交叉熵损失函数中调整各类别损失的贡献比例，抵消多数类样本因数量优势导致的梯度偏置，使模型参数更新更倾向于修正少数类误判，最终显著提升少数类的 召回率（核心评估指标，需体现类别均衡性）。

答案：损失权重（或样本权重）；召回率（或 TPR / 真阳性率）。

3. 在 Logistic 回归使用交叉熵损失来衡量模型的预测结果与真实标签之间的差

异。假设我们有一个样本，其真实标签为 1，模型对该样本的预测概率为 p ，那么该样本的交叉熵损失为 $-\log(p)$ （用 p 表示）。

4. Gradient Boosting 使用损失函数 $L(x, y) = (y - f(x))^2$ 作为目标函数。每次弱学习器学习时，样本的权重为 $-(y - f(x))$ (有无系数均可)。

得分

四、计算题（每题 5-10 分，共 20 分）

请在答题纸对应题号后的空格处顺序填写答案。

1. 令函数 $L(y, f(x)) = 1 - e^{-yf(x)}$ 作为目标函数。请用 gradient boosting 对该损失函数进行优化求解。其中，弱分类器为决策回归树 $CART(x)$ 。计算出在 boosting 迭代过程中得需要拟合的数值。

答：对 $f(x)$ 求导后取负数。

2. 假设有 3 个错分样本，它们的函数间隔分别为 -1、-2、-3，计算感知机的损失函数值。

答案： $yf(x)$ 为函数间隔，表示样本的可分性；而损失函数 $L = -\sum yf(x)$ ； $-(-1-2-3)=6$ 。

4. 已知感知机的训练样本集如下 ($x \in R^2$ 为二维特征向量, $y \in \{\pm 1\}$ 为真实标签):

样本序号	特征向量	真实标签
1	(3,1)	+1
2	(1,3)	+1

学到的权重向量 $w=(-1,2)$ ，偏置 $b=-3$ 。要求：

- 1 判定所有样本中哪些是误分类样本（需写出判定依据）；

答： $wx+b=-3+2-3=2>0$ 判断为正样本，但是标签为+1，正确样本；

$Wx+b=-1+6-3=3>0$ ，判断为正样本，标签为+1,正确分类；

- 2 计算每个误分类样本的函数间隔；

答：2x1, 3x1

- 3 基于感知机的原始损失函数（仅考虑误分类样本），计算最终的损失函数值。

答: 0

得分

五、分析题（每题 10 分，共 10 分）

请在答题纸对应题号下方标明具体题号、顺序作答。

在线性分类器 $y = \mathbf{w}^T \mathbf{x} + b$ 为基础的感知机或 logistic 回归中，我们通常需要对输入向量 $\mathbf{x}$ 进行归一化。请分析模式识别系统里面：

- (a) 归一化有哪些方法，请列出 2 种，并解释每种归一化方法的特点；（2 分）；
 (b) 综合 $y = \mathbf{w}^T \mathbf{x} + b$ 数学表达式和对推理证据信 $\mathbf{x}$ 任度的角度，详细阐述为什么一定需要对输入进行归一化的原因（2 分）；




图 2 图像中关节的位置估计

- (c) 如图 2 所示，在大小为 $H \times W$ 的图像中（ H 为图像的高而 W 为图像的宽），在头部关节点 (x, y) 位置的估计问题中，损失函数为： $L(x, \hat{x}) = \|x - \hat{x}\|^2 + \|y - \hat{y}\|^2$ ，其中， $x \in \mathbb{R}^1$ 为头部的横坐标值，而 $\hat{x} \in \mathbb{R}^1$ 为估计的横坐标值，相应地 $y \in \mathbb{R}^1$ 为头部的纵坐标值，而 $\hat{y} \in \mathbb{R}^1$ 为估计的纵坐标值。其中，估计量为坐标的期望， $\hat{x} = \sum_{i=1}^W i \cdot p_i$ ， $\hat{y} = \sum_{j=1}^H j \cdot p_j$ ， $i(1 \leq i \leq W)$ 是横坐标值，而 $j(1 \leq j \leq H)$ 是纵坐标值，变量 $p_i(p_i \geq 0)$ ($p_j(p_j \geq 0)$) 为坐标点 $i(j)$ 为头部关节点位置 $x(y)$ 的概率值。从归一化角度和损失函数梯度的角度，分析该损失函数有何本质上无法避免的问题（往年题目，今年不出这么发散的题）。

2. 当数据存在噪声时，感知机基于这种损失函数的训练过程会受到怎样的影响？如何改善？

答案：数据存在噪声时，噪声可能导致样本被错误分类，从而增加错分样本的数

量，使损失函数值增大。而且噪声可能会干扰模型的训练方向，导致模型在优化损失函数时出现偏差。

改善的方法可以是对数据进行预处理，去除或减少噪声。也可以采用一些鲁棒性的训练方法，如调整学习率，让模型在训练过程中更稳定地优化损失函数。

3.感知机的原始损失函数定义为 $L(w, b) = - \sum_{x_i \in M} y_i (wx_i + b)$ （其中 M 为误分类样本集合， $y_i \in \{\pm 1\}$ 为真实标签），其训练核心是通过梯度下降迭代更新参数 w 和 b 。请结合感知机的训练机制、损失函数特性，详细分析：

当数据存在标签噪声（如人工标注错误导致 y_i 与真实类别不符）时，训练过程会受到哪些具体影响？请从决策边界的影响这个维度展开讨论，结合数学逻辑或迭代过程说明。

答：决策边界由误分类样本的函数间隔主导，标签噪声会改变决策边界，甚至让线性可分问题变为不可分问题，让感知机无法收敛。

2.