

1.1 什么是人工智能

- 人工智能 (artificial intelligence, AI) 定义为: 任何感知环境并采取行动以类似人的方式实现其目标的设备, 即一种能够像人类一样进行思考、判断、行动等, 能够使用类似人类的方式对外界刺激做出反应的智能机器。
- 模式识别: 利用统计规律来发现数据中的规律, 并利用该规律来进行预测, 尤其将数据预测分类到不同的类别中。
- 一个典型的模式识别过程包括: 数据抽取过程中的规范化, 数据的预处理, 数据的规范化, 根据问题建立模型, 训练模型, 利用模型进行预测, 系统地部署, 根据预测结果对上述过程进行改进。上述过程中, 各个阶段需要注重的典型问题及动机。
- 机器学习: 对于某类任务 T 和性能指标 P , 若一个计算机程序在任务 T 中以指标 P 的性能随着经验 E 而自我改善, 则我们称该程序在从经验 E 中学习。传统机器学习关注模式识别中“根据问题建立模型”, 并对模型的理论特点进行分析, 包括模型精度的上下解, 模型的收敛性, 模型的等效性。

模式识别的分类

- 模式识别就是指从数据中挖掘出复杂物理世界所掌控的自然规律。模式识别所研究的重点就是如何有效设计模式识别的各个阶段对自然规律从数据的角度进行挖掘和表示。
- 自然界中哪些脱离模型的典型规律:
 - ① 统计中的规律: 均值、方差、大数定理, 假设检验
- 模式识别的分类:
 1. 有监督学习: 监督学习是指有标记指导的学习过程;
 2. 无监督学习: 无监督学习所使用的数据集, 不含任何标签, 例如聚类;
 3. 半监督学习: 由于数据的标记会花费大量的人力和时间, 半监督学习同时使用标记数据和未标记数据从而减少训练样本的标记量。

模式识别数学基础

- 贝叶斯公式
 1. 理解证据, 先验, 消元的含义;
 2. 理解贝叶斯公式证据的增加会带来新的先验。
- 函数的凹凸性
 1. 凹凸函数的判断方法;
- 导数的含义:
 1. 函数变化速度最快的方向-> 一阶梯度下降优化方法;
 2. 函数的形状在局部的近似-> 函数在局部区域内的逼近方法。
- 泰勒展开:
 1. 函数在局部点任意阶的近似-> 函数在局部区域内的逼近方法和不等式证明。
- 基于梯度下降的优化
 1. 基于梯度下降的优化公式;

2. 对于凹函数而言，理解学习率与梯度下降迭代次数的关系；
 3. 理解梯度下降过程，并能画出梯度下降中，梯度，学习率和优化点的几何关系；
 4. 一阶梯度下降与函数一阶泰勒展开的关系；
 5. 理解学习率大小与目标函数优化速度之间的关系；
 6. 对于一个向量组成的变量而言，理解学习率对于向量不同分量最有解的影响；
 7. 会用程序实现基于梯度下降的目标优化算法；
- 基本编程能力
 1. 会使用 OPENCV, PYTORCH, Sci-Py, scikit-learn, NumPy, scikit-image, Matplotlib
 - 利用贝叶斯公式作为推理依据，实现 MNIST 手写字符识别
 1. 理解模式识别基本过程中的步骤，数据的预处理，数据的规范化，根据问题建立模型，训练模型，利用模型进行预测，系统地部署，根据预测结果对上述过程进行改进；
 2. 理解先验概率，似然概率的计算过程；
 3. 理解朴素贝叶斯在 MNIST 中能成功地条件并能找到实验证据；
 4. 理解拉普拉斯平滑的动机，原理和计算过程；
 5. 能通过实验观测，学生意识到直方图建立概率的编程过程和局限性；

2.参数化的概率密度估计

- 频率学派的基本观点
 1. 概率是一个固定的值；
 2. 概率会随着样本数量的增加而逐渐逼近一个真实的固定值；
 3. 频率学派认为事实的规律完全来源于对于似然函数的估计；
- 贝叶斯学派的基本观点
 1. 概率不是一个固定值，而是一个随机变量；
 2. 先验分布代表我们对过去知识的理解，而似然函数代表目前收集到数据中获得到的证据，概率分布应该由先验和事实共同决定；
- 最大似然估计
 1. 最大似然估计的本质是让样本出现的概率最大化，即对数据规律的掌握等价于数据的最大化出现；
 2. 对数据规律用参数 θ 进行最大似然估计（记忆）后，我们可以利用贝叶斯公式进行预测；
 3. 样本的独立同分布假设让最大似然估计的联合概率密度变为连乘的形式：

$$P(x_1, \dots, x_i, \dots, x_N | \theta) = \prod_{i=1}^N P(x_i | \theta)$$
 4. 理解最大似然估计中，我们必须对概率密度的形式进行提前约定中存在的问题，这等价于频率学派认为概率是固定值的问题。
- 高斯分布（正态分布）
 1. 掌握基本的数学公式；
 2. 理解高斯分布中均值、方差的含义；
 3. 通过高斯分布对参数的估计，理解无偏估计是理论上好的估计方法，而有偏估计理论上坏的方法；
 4. 理解大数定律关于某个变量说明是最终收敛与正态分布；
 5. 理解置信度是对估计不确定性的一种建模；
 6. 理解高斯分布为 short-tailed 分布；

7. 理解好的估计方法不仅是无偏估计，而且估计的方差还小。
- 掌握多维高斯分布（多元正态分布）
 1. 理解多维高斯分布中协方差矩阵是半正定、对称矩阵的含义（半正定：）；
 2. 由于协方差矩阵的大小与特征向量的平方关系，我们需要对协方差矩阵进行不同程度的约简，包括：保留协方差矩阵的所有元素，只保留对角线上的元素，和只保留对角线上的元素并且对角线上的元素都相同。
- 最大后验估计
 1. 最大后验估计是融合先验知识的最大似然估计；
 2. 最大后验估计也是将参数 θ 无关的消元项进行省略的最大似然估计；
 3. 理解高斯分布先验下的参数估计等价于 Tikhonov regularization 吉洪诺夫正则化（L2 正则化）。
 4. 理解先验选择是靠经验选择的过程，不同的先验代表我们对模型参数的不同理解和约束；

感知机

- 感知机对单个神经元进行模拟进行分类
 1. 感知机将模式在欧式空间中（向量空间）通过内积的方式进行分类证据的积累；
 2. 偏置 b 是与符号函数 $\text{sign}(x)$ 进行配合实现以 0 为阈值进行分类判断；
 3. 向量空间意味着同一向量中不同的维度应具有可比性，例如， a 表示身高（米），而 b 表示体重（KG）直接组成向量 $[a, b]^T$ ，其维度之间不具有可比性。
- 感知机的损失函数
 1. 感知的损失函数是最小化错分样本的函数间隔和；
 2. 函数间隔表示样本点在分类函数在特征空间中对样本的可分性；
 3. 替代函数的思想是模式识别和机器学习的重要策略。
- 感知机的学习算法
 1. 梯度下降算法对感知机目标函数的具体应用；
 2. 一次优化迭代中，用所有样本的为梯度下降，用小部分样本的为最小批梯度下降，用一个样本的为随机梯度下降；
 3. 感知机的实现过程中应建立对损失函数，前后参数范数变化、训练集和验证集上的性能指标随着训练迭代次数的变化曲线。学会观测算法的运行特点，从而发现算法的调试错误和改进。
- 数据归一化
 1. 最小最大线性归一化只能将特征线性变换到 0-1 的区间，解决特征取值范围的问题；
 2. 零均值归一化将特征的中心进行对齐，并变换到均值为 0、标准差为 1 的分布上，能解决特征的对齐问题；
 3. 特征的对齐本质是解决将多个不同类型的特征强扭到同一个向量空间带来的原点不对齐和不可比问题；
 4. 不同的数据和问题会利用到不同的归一化；
 5. 归一化会影响模型是否能快速收敛到理想的局部最小点；
 6. 归一化也会影响模型预测的稳定性。
- 感知机的改进
 1. 从决策面对于随机变量随机性进行约束引入 margin 的概念；

2. 观测 margin 的有无会极大提高决策面稳定性。
- 感知机的对偶问题
 1. 感知机解的对偶问题是从随机梯度下降的迭代公式展开获得;
 2. 感知机解的对偶形式将梯度下降的向量空间转换为样本之间的内乘积空间;
 3. Gram 矩阵计算量是样本数量的平方;
 4. 感知机解的对偶形式是对解的另在解的迭代过程的理解;
 5. 损失函数, 损失函数的梯度和解的最终形式是我们理解模型的三个层次和方法。

5 逻辑斯回归

- Sigmoid 函数的物理意义
 1. Sigmoid 函数的导数计算过程;
 2. Sigmoid 函数能将证据转换为概率的过程。
- 逻辑斯回归的最大似然估计
 1. 与感知机相比, 逻辑斯回归将符号函数转换为 Sigmoid 函数;
 2. 逻辑斯回归将证据转换为事件出现的概率后, 对 2 分类问题用 0-1 概率密度进行建模, 用最大似然估计进行参数的密度估计;
 3. 逻辑斯回归的损失函数等价于交叉熵;
 4. 逻辑斯回归解仍然是关注难分的样本点。
- 多类分类问题
 1. 多类分类问题用 1 对多会带来类别的不平衡问题;
 2. 归一化指数函数 (softmax 函数) 将证据转换为多类预测的概率密度;
 3. Softmax 函数特点是将证据响应大的类继续拔高, 而将响应低的类进行压抑。
- 数据不均衡分类问题
 1. 数据不均衡是普遍存在的现实问题, 是现实 long-tailed 现象的描述;
 2. 处理数据不均衡的手段有过采样和欠采样两种手段。
- 分类性能评价
 1. 在数据均衡的情况下, 准确率就能反映系统的性能, 但在数据不均衡的情况下, 我们需要引入二分类的混淆矩阵;
 2. 理解利用二元分类的混淆矩阵正对少量样本类的评估方法, 查准率和召回率;
 3. 理解 ROC 曲线的计算过程。

集成学习

- 集成学习的分类
 1. 集成学习的动机是将能力弱的学习器进行组合后获得能力更强的强分学习器;
 2. 将多个弱学习器加法叠加在一起-> bagging 和 boosting;
 3. 乘法集成学习-> 无法将弱能力的学习器组合后变强;
 4. 将多个弱学习器层次的累叠在一起-> 深度神经网络;
 5. 集成学习对弱学习器必须有一定的限制条件, 包括, 易于训练和并行化, 弱学习器之间应该有某种互补性, 必须在一定原则下进行集成。
- 学习器的优劣和泛化误差
 1. 泛化误差是指利用不同的训练集合 (可能是独立同分布) 对模型进行多次训练后,

对同一测试集合误差的期望；

2. 掌握偏差-方差分解过程中的假设和推导过程；
3. 弱学习器用偏差和方差进行刻画；

- 模型选择与交叉验证

1. 训练集、验证集都属于训练集，而测试集和训练集构成全部数据；这三个集合之间互相没有交集；
2. 因为对数据集的一次固定（随机）划分，验证集或测试集里面仍然存在偏好（例如，某些特殊的数据出现在测试集里面，而训练集少甚至没有）；
3. K 折交叉验证是加强版本的交叉验证，是一种让样本都有一次机会成为验证集，是样本某个指标平均意义下对模型的选择；
4. 理解高偏差，高方差，低偏差，低方差及其组合在：1）随着样本数增加；2）随着模型复杂度变化，这两个因素下的性能（误差）的表现；

- Bagging

1. Bagging 就是对具有低偏差但高方差学习器进行集成；
2. 低偏差是指每个学习器分类能力强，容易会存在过拟合现象，高方差是指每个学习器预测当训练集变化时候，学习器的预测变化也很大。决策树是典型的低偏差但高方差的学习器；
3. Bagging 的方差和偏差的推导过程所用的数学技巧；
4. Bagging 为了让强分类器的方差减少，让弱学习器权重变小，相关性也变小；
5. Bagging 为了让强学习器的偏差减少，我们需要所有弱学习的偏差都小，并且希望偏差差异越小越好。
6. Bagging 的包外数据及其比例的推导过程；
7. 证明有放回的采样方法获得的样本子集与全样本集合属于同一分布。
8. 理解 SVM 作为弱学习器无法获得有效的 bagging 结果，而决策树的 bagging 能获得有效的 bagging 结果。

- 随机森林

1. 在特征层面和样本层面进行随机的特征抽取和样本抽取；随机化能降低随机森林中决策树的相关性；
2. 从袋外数据产生过程理解随机森林中决策树之间仍然有相关性。

- Boosting 算法

1. Boosting 算法偏差需要弱学习器系数小于 1 的原因；
2. Boosting 算法方差需要减少需要系数小于 $1/M$ 的原因，弱分类器数量为 M ；
3. adaBoost 的迭代优化过程；
4. AdaBoost 算法是指数损失情况下的推导过程；
5. Boosting 是损失函数在函数空间中的 Taylor 展开过程；
6. 能用代码实现 boosting 算法；
7. Boosting 本质是针对高偏差而低方差的弱学习器；
8. Boosting 本质是在函数空间中对梯度的回归拟合过程。